

澳門城市大學
Universidade da Cidade de Macau
City University of Macau

博士課程書面報告

基於神經網絡的氣象數據超分辨率方法

Neural Network-Based Methods for Meteorological Data Super-Resolution

姓　　名	Name	：	馬佳慧
學　　號	Student No.	：	D26092100229
院　　系	Faculty	：	數據科學學院
課　　程	Program	：	數據科學前沿分析研究
指導教師	Supervisor	：	劉文堅
電　　郵	Email	：	D26092100229@cityu.edu.com

2026 年 11 月 20 日

基於神經網絡的氣象數據超分辨率方法

摘要：氣象數據是氣象預警、可再生能源評估等工作的重要基礎，但受觀測與計算條件限制，常用氣象再分析資料空間解析度偏低，難以滿足局地精細化應用需求。相較於普通影像超解析度，氣象場具備物理連續性、強非線性等特徵，低解析度數據並非簡單下採樣所得，使得氣象超解析度存在較大技術難點。本文以 ERA5 再分析資料為研究對象，梳理動力降尺度、傳統統計插值、深度學習三類主流氣象降尺度與超解析度技術路線，針對現有深度學習方法計算成本大、多僅適配單一氣象要素等不足，提出一套包含數據獲取、空間重採樣、雙三次插值預放大、兩級卷積網路數據重建的氣象數據超解析度處理方案。該方案先透過雙三次插值完成尺寸對齊，建構低頻資訊基線，再利用兩級卷積網路採取由粗到精的策略分步完成特徵提取與細節精修，降低網路學習難度，兼顧輸出結果的物理合理性與計算效率。

關鍵詞：氣象超分辨率；ERA5 再分析資料；卷積神經網絡

1. 緒論

1.1 研究背景

氣象數據是天氣預警、氣候評估、可再生能源開發利用，以及災害性天氣預報的重要基礎。然而，受觀測手段、存儲成本和數值模式計算資源的限制，氣象數據通常以相對粗糙的空間分辨率發布。以歐洲中期天氣預報中心（ECMWF）的再分析資料 ERA5 為例，其標準網格分辨率約為 0.25°（約 25 公里），而在實際應用中，例如在區域風電場選址、局地強降水預警、城市尺度熱環境分析等方面，往往需要公里級甚至百米級的高分辨率場。這種「數據分辨率與應用需求」之間的顯著落差，使氣象數據超分辨率成為亟待解決的問題。

與普通自然圖像的超分辨率（Super-Resolution, SR）相比，氣象場存在兩個突出難點：一是氣象要素，比如溫度、風場、降水量等，在空間上具有強烈的物理連續性、尺度相關性與非線性，簡單放大會產生物理不合理的結果；第二方面就是低分辨率與高分辨率之間並非簡單的下採樣關係，低分辨率網格上的數值往

往已經過平均或再分析同化處理，丟失了真實的高頻細節。因此，能否從低分辨率氣象數據中恢復出既高頻、又物理可信的精細場，是一項具有明確科學價值與應用價值的研究問題。

1.2 數據集

本研究使用的數據取自歐洲中期天氣預報中心（ECMWF）第五代再分析資料集（ERA5），該資料集為公開可用資源。ERA5 提供 1950 年至今全球天氣與氣候變數的高解析度再分析數據，涵蓋大氣、陸地與海洋氣候參數。該資料集包含完備的氣候資訊，對於氣候研究與預測建模具有重要價值。本研究採用的溫度數據取自 ERA5 單層逐小時資料集，時間範圍為 1940 年至今；其空間解析度為 0.25°×0.25°，約等同 25 公里的網格間距。具體而言，本研究選用 2 公尺溫度參數，代表陸地、海洋或內陸水體地表上方 2 公尺處的氣溫。該參數透過模式最低層與地表之間的插值計算得到，並納入大氣的物理條件。從 ERA5 數據集中提取經緯度範圍北緯 16.25-40°、東經 100-123.75°，時間為 1940 年 1 月 1 日至 1940 年 12 月 31 日的日平均溫度信息作爲本次研究數據，總共包含 366 筆樣本。其中，前 256 天為訓練集，第 257 天至 311 天為驗證集，第 312 天至 366 天為測試集。空間分辨率为 0.25°的 1940 年 1 月 1 日日平均溫度圖如圖 1.1 所示。

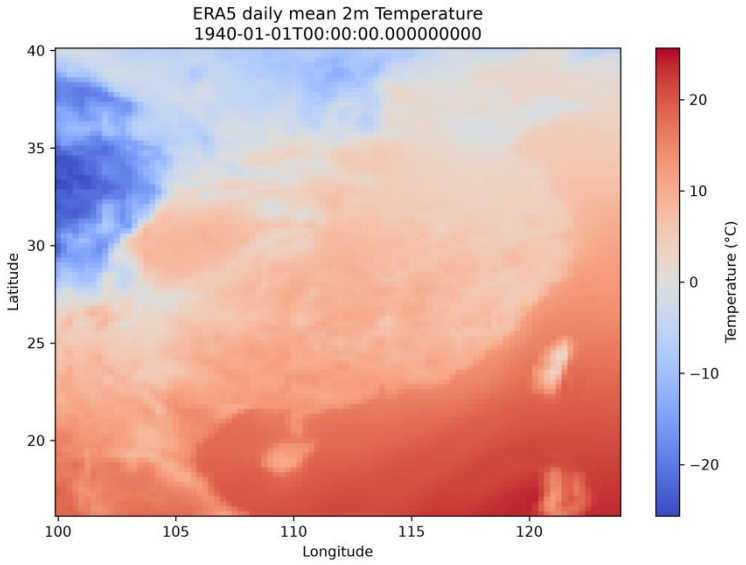


图 1.1　1940 年 1 月 1 日日平均溫度圖

2. 相關工作

隨著社會發展對氣象超分辨率需求的加劇，氣象降尺度與氣象超分辨率的研究早在很久之前就得到了研究者的廣泛關注。最早出現的氣象降尺度為動力降尺度，即利用區域氣候模式在粗分辨率全球模式的邊界驅動下進行高分辨率模擬。這類方法物理機制明確，但計算成本非常大，難以滿足實時或氣象數據批量處理需求。

因此，研究者們提出氣象數據插值降尺度方法，最具代表性的為雙三次插值、雙線性插值等方法。這類方法簡單有效，這類方法主要依靠鄰近格點的數值做數學平滑運算生成新像素，並不引入氣象場背後的物理約束，重建結果容易過度平滑，細節結構被抹平。局地的溫度梯度、冷暖中心邊界、地形誘發的小尺度氣象異常等精細特徵會衰減甚至消失，空間場趨向均勻，難以還原真實氣象場的非均勻與突變特徵。同時插值結果僅是數值上的過渡，無法反映陸面、地形對氣象要素的調控作用，容易出現物理上不合理的空間分布。這也導致插值生成的高分辨率產品，在極端氣象、局地熱環境等精細化研究中預報與分析能力不足，僅能滿足粗略空間補全需求，對高頻細節和極端事件的恢復能力有限。

近年來，基於深度學習的超分辨率方法成為氣象降尺度領域的研究熱點。Thomas 等人[1]提出 DeepSD 模型藉助堆疊稀疏自編碼器實現氣象降尺度；SRCNN 及其改進版本 SE-SRCNN[2]，已應用於降水、溫度場的超分辨率重建；Hyebin[3]等人设计 SR-Weather 框架構建成對氣象樣本數據集，依託多種 SRCNN 變體開展對比試驗。隨著生成式模型快速發展，擴散模型[4]也逐步用於降水降尺度與預報任務，小波域條件擴散降水超分、潛空間殘差擴散模型等方案，可生成具備物理一致性的集合預報結果。現有研究證實，深度學習方案的整體重建效果優於傳統插值與統計降尺度方法，但仍存在短板，比如部分生成模型結構複雜、計算開銷高昂，還有不少模型僅適配單一氣象要素，跨場景泛化能力不足。針對上述問題，本文採用“插值預放大+多級卷積網絡”的輕量化級聯結構，在保障重建結

果物理合理性的前提下削減計算開銷，為氣象超分辨率技術提供新的補充方案並完成有效性驗證。

3. 方案设计以及实验分析

3.1 实验方案设计

本文提出一種基於插值預放大與殘差卷積網絡的氣象數據超分辨率重建方案。首先，原始 ERA5 數據空間分辨率為 0.25°，對測試集執行降採樣操作，得到分辨率 0.5°的低分辨率數據。隨後採用雙三次插值，將 0.5°低分辨率數據上採樣回 0.25°分辨率，以此作為模型輸入。輸入數據先送入兩層卷積神經網絡初步提取氣象場空間特徵，完成粗粒度重建；再將該輸出的結果送入殘差神經網絡，進一步學習細節殘差信息，修正粗重建結果，最終輸出氣象超分辨率重建結果。該流程以插值提供基礎輪廓，依靠卷積層提取淺層特徵，藉助殘差網絡彌補高頻細節，兼顧重建效率與細節還原能力。

3.2 性能评价指标

本研究首先採用機器學習與電腦視覺領域常用的評價指標，包括均方根誤差（Root Mean Square Error, RMSE）、平均絕對誤差（Mean Absolute Error，MAE）、平均絕對百分比誤差（Mean Absolute Percentage Erro, MAPE）、相關係數（correlation coefficient, Corr），具體公式如下所示。

$$RMSE(x,y) = \sqrt{\frac{\sum_{j=1}^{P}\sum_{i=1}^{N}(x_i^j - y_i^j)^2}{N \cdot P}} \tag{3-1}$$

$$MAE(x,y) = \frac{\sum_{j=1}^{P}\sum_{i=1}^{N}\left|x_i^j - y_i^j\right|}{N \cdot P} \tag{3-2}$$

$$Corr(x,y) = \frac{(2\mu_x\mu_y + C_1)(2\sigma_{xy} + C_2)}{(\mu_x{}^2 + \mu_y{}^2 + C_1)(\sigma_x{}^2 + \sigma_y{}^2 + C_2)} \tag{3-3}$$

其中，P 是指總樣本數，N 是指一個樣本上的像素點，x_i^j和y_i^j分別表示的是在原始數據和超分辨率數據中第 j 個樣本的第 i 個像素點，$j \in P$, $i \in N$；μ_x和μ_y分別表示

的是原始數據和超分辨率數據的平均溫度；σ_x和σ_y分別表示的是原始數據和超分辨率數據的標準差；σ_{xy}指的是原始數據和超分辨率數據之間的協方差。在上述三個性能指標中，RMSE 和 MAE 用來觀測衡量模型輸出的結果與真實結果的誤差程度，二者的指標是越小越好，而對於 Corr 是用來衡量模型輸出數據與原始真實數據的相似程度，其結果越接近 1 越好。

3.3 實驗結果分析

圖 3.1 為雙三次插值基線方法在 1940 年 11 月 7 日 2m 氣溫場的超分辨率對比結果。左圖為低分辨率輸入場，空間分辨率 0.5°，網格規模 48×48；右圖為經雙三次插值上採樣至 0.25°的重建結果，兩圖採用統一色標以保證空間與數值上的橫向可比。

從空間結構看，研究區域氣溫整體呈西北冷、東南暖的分布格局：北部（Grid y 較小區域）以藍調為主，氣溫多在 0℃以下，西北局部冷中心低至-10℃上下；南部及東南部為大片紅色暖區，氣溫普遍升至 15～25 ℃；區域中部偏西存在一個閉合暖中心。對比兩圖可見，雙三次插值完整保留了低分辨率場的大尺度溫度梯度與暖中心位置，插值後網格數由 48×48 提升至約 96×96，色塊邊界由原來的塊狀跳變變為連續過渡；但重建場整體偏平滑，大尺度梯度被保留的同時，原 0.5°網格攜帶的信息並未被真正加密，未能生成地形、海陸差異驅動的小尺度溫度起伏與局地極值，直觀體現了純數學插值過度平滑、高頻細節缺失的固有局限

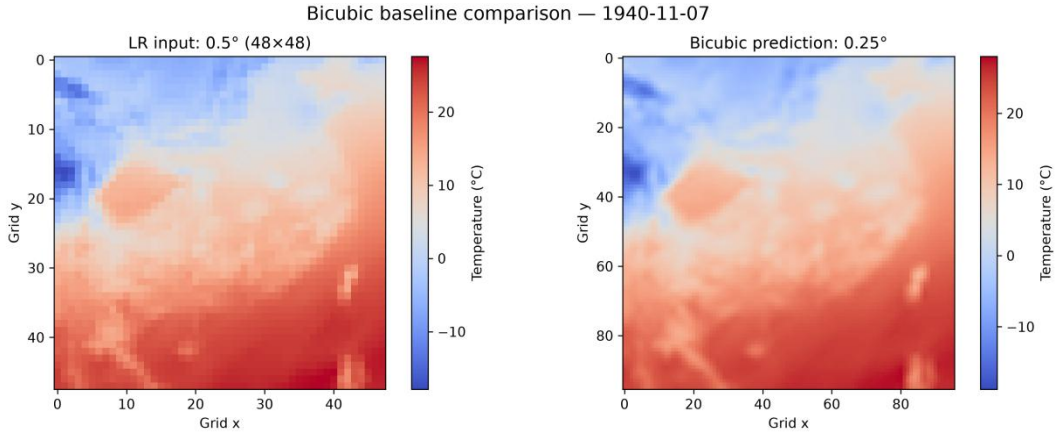


圖 3.1 雙三次插值方法輸出的實驗結果

本文所提模型與傳統雙三次插值方法開展對比試驗，逐日平均絕對誤差（MAE）結果如圖 3.2 所示。從整體變化趨勢來看，DOUBLE-CNN 對應的 MAE

曲線全程位於雙三次插值曲線下方，說明在整個測試時段內，所提模型的逐日誤差均低於雙三次插值，重建精度更優。兩條曲線的波動趨勢具有一定相似性，反映出誤差變化會隨氣象場狀態同步變化；但雙三次插值的誤差峰值更高、誤差波動幅度更大，而 DOUBLE-CNN 可以有效壓低誤差上限，降低氣象場重建的偏差。在測試週期內，雙三次插值的 MAE 整體維持在 0.23-0.27℃區間，DOUBLE-CNN 的 MAE 大多集中在 0.20-0.25℃，驗證了深度學習方法相比傳統插值，能夠更好地還原溫度場的空間細節，緩解插值帶來的過度平滑問題。

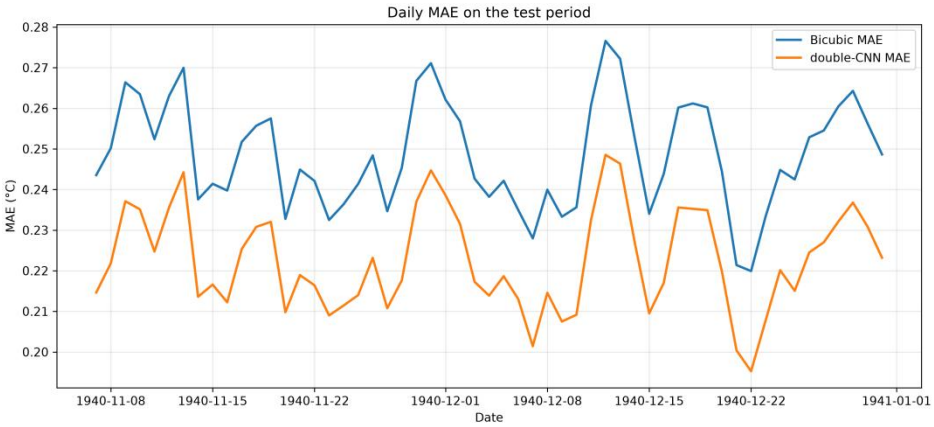


图 3.2 逐日平均絕對誤差

圖 3.3 為雙三次插值方法與本文所提 double-CNN 模型的空間平均絕對誤差（MAE）分布，以及誤差改善量空間分布。從左圖雙三次插值的 MAE 空間場可以看出，該方法在研究區域內存在多處高誤差斑塊，這些區域的溫度重建偏差相對更大；中間 double-CNN 模型的 MAE 空間圖整體誤差水平更低，高誤差區域的偏差得到明顯抑制。右側差值圖為雙三次插值 MAE 減去 double-CNN 模型 MAE 的改善結果，圖中絕大多數區域呈暖色，代表 double-CNN 模型的 MAE 小於雙三次插值，取得正向精度提升，在左側及右下角部分區域改善效果尤為顯著；僅少量零星區域出現負值，說明在少數網格點上模型效果略差於雙三次插值。整體來看，所提 double-CNN 模型相較傳統雙三次插值能夠有效降低 2m 溫度降尺度重建的空間誤差，提升精細化溫度場的重建精度。

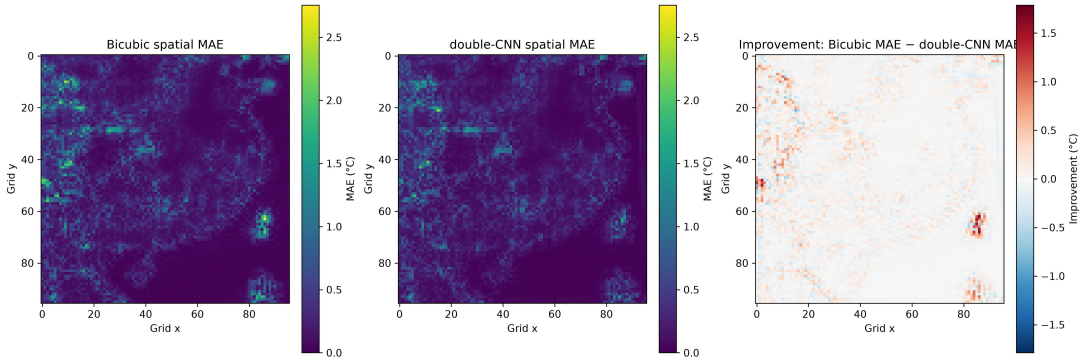


图 3.3 空間平均絕對誤差 MAE 對比分布圖

SRCNN 模型的訓練損失與驗證損失變化曲線如圖 3.4 所示，損失函數採用歸一化溫度的均方誤差。由圖可見，在訓練初期，訓練損失與驗證損失均快速下降，模型快速學習溫度場的特徵；隨著訓練輪次 Epoch 不斷增加，兩條曲線的下降速率逐漸放緩，損失趨於平穩。整個訓練過程中，驗證損失始終低於訓練損失，兩條曲線變化趨勢保持一致，沒有出現驗證損失回升、發散的現象，說明該 SRCNN 模型在本次氣象溫度超分辨率任務中沒有發生明顯過擬合，模型收斂狀態良好，具備穩定的泛化能力。

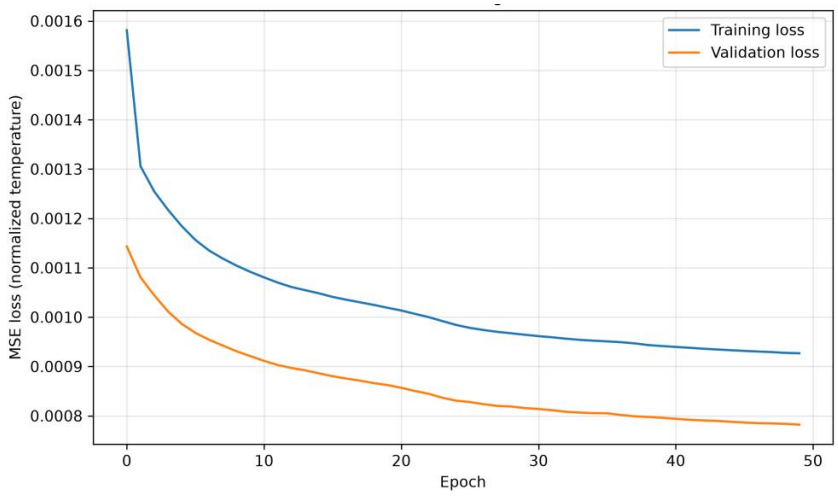


图 3. 4 double-cnn 的訓練損失與驗證損失變化曲線

4. 總結

本文從空間誤差分布、模型訓練收斂特性兩個維度，對比了雙三次插值以及所提 doubleCNN 模型在 2m 氣溫超分辨率重建任務中的表現。從 doubleCNN 的訓練損失曲線可以看出，模型訓練階段的訓練損失與驗證損失同步下降並逐步趨於穩定，全程未出現驗證損失反彈，模型收斂良好，不存在明顯過擬合，具備可靠的泛化基礎。同時，進一步對比雙三次插值與 doubleCNN 的空間 MAE 場分布，從結果中可以看出，傳統雙三次插值方法在研究區內存在多處高誤差斑塊，在地形或者氣象要素變化劇烈區域重建偏差更大，而 doubleCNN 模型對應的空間 MAE 整體水平更低，高誤差區域得到有效抑制。誤差改善場結果顯示，研究區域大部分網格呈現正向提升，說明 doubleCNN 相比雙三次插值能夠有效降低溫度重建誤差，僅少數零星點位精度略弱於插值方法。綜合結果表明，相較於傳統雙三次插值這類僅依靠數學運算的插值方案，基於深度學習的 doubleCNN 模型能夠捕捉氣象溫度場的空間細節特徵，緩解插值方法過度平滑、丟失局地變化信息的缺陷，在氣象降尺度精細化重建上具備明顯優勢；但模型仍存在少量區域提升有限的問題，後續可針對高誤差區域進一步優化模型結構與訓練策略。

参考文献：

[1] Vandal T, Kodra E, Ganguly S, et al. Deepsd: Generating high resolution climate change projections through single image super-resolution[C]//Proceedings of the 23rd acm sigkdd international conference on knowledge discovery and data mining. 2017: 1663-1672.

[2] Park Hyebin, Park S, Kang D, et al. A super-resolution framework for downscaling machine learning weather prediction toward 1-km air temperature[J]. npj Climate and Atmospheric Science, 2026, 9(1): 56.

[3] Kingston K, Boucher O, Bouchet F, et al. IPSL-AID: Generative Diffusion Models for Climate Downscaling from Global to Regional Scales[J]. arXiv preprint arXiv:2604.03275, 2026.

[4] Han, D. Comparison of Commonly Used Image Interpolation Methods. In Proceedings of the 2nd International Conference on Computer Science and Electronics Engineering (ICCSEE 2013); Atlantis Press: Paris, France, 2013; pp. 1556–1559.

[5] Hsu A, Sheriff G, Chakraborty T, et al. Disproportionate exposure to urban heat island intensity across major US cities[J]. Nature communications, 2021, 12(1): 2721.

[6] Prein A F, Langhans W, Fosser G, et al. A review on regional convection‐permitting climate modeling: Demonstrations, prospects, and challenges[J]. Reviews of geophysics, 2015, 53(2): 323-361.

[7] Dowell D C, Alexander C R, James E P, et al. The High-Resolution Rapid Refresh (HRRR): An hourly updating convection-allowing forecast model. Part I: Motivation and system description[J]. Weather and Forecasting, 2022, 37(8): 1371-1395.

[8] Beltrami, H. On the relationship between ground temperature histories and meteorological records: A report on the Pomquet station. Glob. Planet. Change 2001, 29, 327–348.

[9] Du, Y.; Zhang, Q.; Chen, Y.L.; Zhao, Y.; Wang, X. Numerical simulations of spatial distributions and diurnal variations of low-level jets in China during early summer. J. Clim. 2014, 27, 5747–5767.

[10] Han, D. Comparison of Commonly Used Image Interpolation Methods. In Proceedings of the 2nd International Conference on Computer Science and Electronics Engineering (ICCSEE 2013); Atlantis Press: Paris, France, 2013; pp. 1556–1559.